

Sessão 2.3: Exploração Inicial dos Dados” author: “Norberto Jorge Gonçalves

6 de Julho de 2025

Contents

1. Exploração Inicial dos Dados	1
1.1. head() e tail(): Ver o Início e o Fim	1
1.2. str(): Estrutura do Objeto	2
1.3. summary(): Resumo Estatístico	2
1.4. dim(): Dimensões do Data Frame	3
1.5. colnames() e names(): Nomes das Colunas	3
1.6. nrow() e ncol(): Número de Linhas e Colunas	3

1. Exploração Inicial dos Dados

Depois de importar os dados para o R, o próximo passo crucial é explorá-los. Isto ajuda-nos a entender a sua estrutura, conteúdo e a identificar potenciais problemas antes de qualquer análise aprofundada. Vamos usar um conjunto de dados de exemplo incorporado no R, o `iris` dataset, que contém medições de diferentes espécies de flores.

```
# Carregar o dataset iris (já vem com o R)
data(iris)

# Visualizar as primeiras 6 linhas do dataset
head(iris)
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2 setosa
## 2          4.9          3.0          1.4          0.2 setosa
## 3          4.7          3.2          1.3          0.2 setosa
## 4          4.6          3.1          1.5          0.2 setosa
## 5          5.0          3.6          1.4          0.2 setosa
## 6          5.4          3.9          1.7          0.4 setosa
```

1.1. head() e tail(): Ver o Início e o Fim

- `head(dataset)`: Mostra as primeiras 6 linhas do data frame.
- `tail(dataset)`: Mostra as últimas 6 linhas do data frame. Estas funções são ótimas para ter uma ideia rápida de como os dados estão organizados.

```
# Ver as primeiras 10 linhas
head(iris, n = 10)
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2 setosa
## 2          4.9          3.0          1.4          0.2 setosa
## 3          4.7          3.2          1.3          0.2 setosa
## 4          4.6          3.1          1.5          0.2 setosa
```

```
## 5          5.0          3.6          1.4          0.2 setosa
## 6          5.4          3.9          1.7          0.4 setosa
## 7          4.6          3.4          1.4          0.3 setosa
## 8          5.0          3.4          1.5          0.2 setosa
## 9          4.4          2.9          1.4          0.2 setosa
## 10         4.9          3.1          1.5          0.1 setosa
```

```
# Ver as últimas 3 linhas
tail(iris, n = 3)
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
## 148          6.5          3.0          5.2          2.0 virginica
## 149          6.2          3.4          5.4          2.3 virginica
## 150          5.9          3.0          5.1          1.8 virginica
```

1.2. str(): Estrutura do Objeto

A função `str()` (de “structure”) é uma das mais úteis. Ela mostra a estrutura interna de um objeto R, incluindo: * O tipo de objeto (ex: `data.frame`). * O número de observações (linhas) e variáveis (colunas). * Os nomes das colunas. * O tipo de dados de cada coluna (numérico, fator, etc.). * Alguns valores de exemplo de cada coluna.

```
str(iris)
```

```
## 'data.frame':   150 obs. of  5 variables:
## $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
## $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
## $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
## $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
## $ Species     : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
```

Interpretação: * ‘data.frame’: 150 obs. of 5 variables: significa que temos 150 linhas e 5 colunas. * \$ Sepal.Length: num indica que a coluna Sepal.Length é numérica. * \$ Species : Factor w/ 3 levels indica que Species é um fator (variável categórica) com 3 níveis (as diferentes espécies de flores).

1.3. summary(): Resumo Estatístico

A função `summary()` fornece um resumo estatístico para cada coluna do data frame: * Para colunas numéricas: Mínimo, 1º Quartil, Mediana, Média, 3º Quartil, Máximo. * Para colunas categóricas (fatores): Contagem de cada nível.

```
summary(iris)
```

```
##      Sepal.Length      Sepal.Width      Petal.Length      Petal.Width
## Min.   :4.300      Min.   :2.000      Min.   :1.000      Min.   :0.100
## 1st Qu.:5.100      1st Qu.:2.800      1st Qu.:1.600      1st Qu.:0.300
## Median :5.800      Median :3.000      Median :4.350      Median :1.300
## Mean   :5.843      Mean   :3.057      Mean   :3.758      Mean   :1.199
## 3rd Qu.:6.400      3rd Qu.:3.300      3rd Qu.:5.100      3rd Qu.:1.800
## Max.   :7.900      Max.   :4.400      Max.   :6.900      Max.   :2.500
##      Species
## setosa   :50
## versicolor:50
## virginica :50
##
##
##
```

Interpretação: * Para Sepal.Length, vemos as principais medidas de tendência central e dispersão. * Para Species, vemos que há 50 observações de cada uma das três espécies.

1.4. dim(): Dimensões do Data Frame

A função dim() retorna um vetor com o número de linhas e o número de colunas do data frame.

```
dim(iris)

## [1] 150  5

# O primeiro número é o número de linhas, o segundo é o número de colunas.
```

1.5. colnames() e names(): Nomes das Colunas

- colnames(dataset): Retorna um vetor com os nomes das colunas.
- names(dataset): Faz o mesmo que colnames() para data frames.

```
colnames(iris)

## [1] "Sepal.Length" "Sepal.Width" "Petal.Length" "Petal.Width" "Species"

names(iris)

## [1] "Sepal.Length" "Sepal.Width" "Petal.Length" "Petal.Width" "Species"

# Podemos também mudar os nomes das colunas, se necessário
# colnames(iris)[5] <- "Especie" # Mudar o nome da 5ª coluna
# head(iris)
```

1.6. nrow() e ncol(): Número de Linhas e Colunas

- nrow(dataset): Retorna o número de linhas.
- ncol(dataset): Retorna o número de colunas.

```
nrow(iris)

## [1] 150

ncol(iris)

## [1] 5
```