

Sessão 2.4: Seleção e Filtragem de Dados

Norberto Jorge Gonçalves

6 de Julho de 2025

Contents

1. Seleção e Filtragem de Dados	1
1.1. Selecionar Colunas	1
1.1.1. Usando \$ (para uma única coluna)	1
1.1.2. Usando [] com o nome da coluna (para uma ou múltiplas colunas)	2
1.1.3. Usando [] com o índice da coluna	2
1.2. Filtrar Linhas (Seleção de Observações)	3
1.2.1. Filtrar por uma condição numérica	3
1.2.2. Filtrar por uma condição de texto/categórica	3
1.2.3. Combinar Múltiplas Condições	3
1.2.4. Usando %in% para Múltiplas Categorias	4
1.3. Selecionar Colunas e filtrar Linhas	4

1. Seleção e Filtragem de Dados

Depois de explorar os dados, muitas vezes precisamos de selecionar apenas as colunas (variáveis) ou as linhas (observações) que nos interessam para uma análise específica. Nesta sessão, vamos aprender as formas básicas de fazer isso em R. Vamos continuar a usar o dataset `iris`.

```
# Carregar o dataset iris
```

```
data(iris)
```

```
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1         5.1         3.5          1.4          0.2   setosa
## 2         4.9         3.0          1.4          0.2   setosa
## 3         4.7         3.2          1.3          0.2   setosa
## 4         4.6         3.1          1.5          0.2   setosa
## 5         5.0         3.6          1.4          0.2   setosa
## 6         5.4         3.9          1.7          0.4   setosa
```

1.1. Selecionar Colunas

Existem várias formas de selecionar colunas de um data frame.

1.1.1. Usando \$ (para uma única coluna)

Esta é a forma mais comum e simples para aceder a uma única coluna.

```
# Selecionar a coluna 'Sepal.Length'
```

```
comprimento_sepala <- iris$Sepal.Length
```

```
print(head(comprimento_sepala))
```

```
## [1] 5.1 4.9 4.7 4.6 5.0 5.4
```

```
class(comprimento_sepala) # Note que o resultado é um vetor
```

```
## [1] "numeric"
```

1.1.2. Usando [] com o nome da coluna (para uma ou múltiplas colunas)

Podemos usar colchetes [linha, coluna] para selecionar. Se deixarmos a parte da linha vazia, selecionamos todas as linhas.

```
# Selecionar uma única coluna pelo nome (o resultado ainda é um data frame)
comprimento_sepala_df <- iris["Sepal.Length"]
print(head(comprimento_sepala_df))
```

```
##   Sepal.Length
## 1           5.1
## 2           4.9
## 3           4.7
## 4           4.6
## 5           5.0
## 6           5.4
```

```
class(comprimento_sepala_df) # Note que o resultado é um data frame
```

```
## [1] "data.frame"
```

```
# Selecionar múltiplas colunas usando um vetor de nomes
medidas_petala <- iris[ , c("Petal.Length", "Petal.Width")]
print(head(medidas_petala))
```

```
##   Petal.Length Petal.Width
## 1           1.4           0.2
## 2           1.4           0.2
## 3           1.3           0.2
## 4           1.5           0.2
## 5           1.4           0.2
## 6           1.7           0.4
```

1.1.3. Usando [] com o índice da coluna

Podemos também selecionar colunas pela sua posição numérica.

```
# Selecionar a primeira coluna
primeira_coluna <- iris[ , 1]
print(head(primeira_coluna))
```

```
## [1] 5.1 4.9 4.7 4.6 5.0 5.4
```

```
# Selecionar a primeira e a quinta coluna
primeira_e_quinta <- iris[ , c(1, 5)]
print(head(primeira_e_quinta))
```

```
##   Sepal.Length Species
## 1           5.1  setosa
## 2           4.9  setosa
## 3           4.7  setosa
## 4           4.6  setosa
## 5           5.0  setosa
```

```
## 6          5.4 setosa
```

1.2. Filtrar Linhas (Seleção de Observações)

Para filtrar linhas, usamos os colchetes [linha, coluna] e colocamos uma condição lógica na parte da linha. A condição deve resultar num vetor de TRUE ou FALSE para cada linha.

1.2.1. Filtrar por uma condição numérica

```
# Selecionar flores onde o Sepal.Length é maior que 7.0
flores_grandes <- iris[iris$Sepal.Length > 7.0, ]
print(head(flores_grandes))
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
## 103           7.1         3.0         5.9         2.1 virginica
## 106           7.6         3.0         6.6         2.1 virginica
## 108           7.3         2.9         6.3         1.8 virginica
## 110           7.2         3.6         6.1         2.5 virginica
## 118           7.7         3.8         6.7         2.2 virginica
## 119           7.7         2.6         6.9         2.3 virginica
```

```
nrow(flores_grandes) # Quantas flores selecionamos?
```

```
## [1] 12
```

1.2.2. Filtrar por uma condição de texto/categórica

```
# Selecionar apenas as flores da espécie "setosa"
setosa_flores <- iris[iris$Species == "setosa", ]
print(head(setosa_flores))
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
## 1             5.1         3.5         1.4         0.2 setosa
## 2             4.9         3.0         1.4         0.2 setosa
## 3             4.7         3.2         1.3         0.2 setosa
## 4             4.6         3.1         1.5         0.2 setosa
## 5             5.0         3.6         1.4         0.2 setosa
## 6             5.4         3.9         1.7         0.4 setosa
```

```
nrow(setosa_flores) # Deviam ser 50
```

```
## [1] 50
```

1.2.3. Combinar Múltiplas Condições

Podemos usar operadores lógicos para combinar condições: * & (AND): Ambas as condições devem ser verdadeiras. * | (OR): Pelo menos uma das condições deve ser verdadeira.

```
# Selecionar flores da espécie "virginica" E com Petal.Length maior que 6.0
virginica_longa_petala <- iris[iris$Species == "virginica" & iris$Petal.Length > 6.0, ]
print(head(virginica_longa_petala))
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
## 106           7.6         3.0         6.6         2.1 virginica
## 108           7.3         2.9         6.3         1.8 virginica
## 110           7.2         3.6         6.1         2.5 virginica
## 118           7.7         3.8         6.7         2.2 virginica
```

```
## 119      7.7      2.6      6.9      2.3 virginica
## 123      7.7      2.8      6.7      2.0 virginica
```

```
nrow(virginica_longa_petala)
```

```
## [1] 9
```

```
# Selecionar flores da espécie "setosa" OU "versicolor"
```

```
setosa_ou_versicolor <- iris[iris$Species == "setosa" | iris$Species == "versicolor", ]
print(head(setosa_ou_versicolor))
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2  setosa
## 2          4.9          3.0          1.4          0.2  setosa
## 3          4.7          3.2          1.3          0.2  setosa
## 4          4.6          3.1          1.5          0.2  setosa
## 5          5.0          3.6          1.4          0.2  setosa
## 6          5.4          3.9          1.7          0.4  setosa
```

```
nrow(setosa_ou_versicolor) # Deviam ser 100
```

```
## [1] 100
```

1.2.4. Usando %in% para Múltiplas Categorias

Quando queremos filtrar por várias categorias de uma só vez, == pode ser repetitivo. O operador %in% é muito útil.

```
# Selecionar flores da espécie "setosa" ou "versicolor" (forma mais elegante)
```

```
setosa_ou_versicolor_in <- iris[iris$Species %in% c("setosa", "versicolor"), ]
print(head(setosa_ou_versicolor_in))
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2  setosa
## 2          4.9          3.0          1.4          0.2  setosa
## 3          4.7          3.2          1.3          0.2  setosa
## 4          4.6          3.1          1.5          0.2  setosa
## 5          5.0          3.6          1.4          0.2  setosa
## 6          5.4          3.9          1.7          0.4  setosa
```

```
nrow(setosa_ou_versicolor_in)
```

```
## [1] 100
```

1.3. Selecionar Colunas e filtrar Linhas

Podemos combinar a seleção de colunas e a filtragem de linhas na mesma operação.

```
# Selecionar apenas as colunas 'Sepal.Length' e 'Species' para flores da espécie "virginica"
```

```
virginica_selecionado <- iris[iris$Species == "virginica", c("Sepal.Length", "Species")]
print(head(virginica_selecionado))
```

```
##   Sepal.Length  Species
## 101          6.3 virginica
## 102          5.8 virginica
## 103          7.1 virginica
## 104          6.3 virginica
## 105          6.5 virginica
## 106          7.6 virginica
```