

# Sessão 3.4: Tratamento de Valores em Falta (NA)

Os vossos formadores

6 de Julho de 2025

## Contents

|                                                                                |   |
|--------------------------------------------------------------------------------|---|
| 1.1. Criar um Dataset de Exemplo com NAs                                       | 1 |
| 1.2. Identificar Valores em Falta                                              | 1 |
| 1.2.1. <code>is.na()</code> : Verificar se é NA                                | 1 |
| 1.2.2. <code>sum(is.na())</code> : Contar NAs por Coluna                       | 2 |
| 1.2.3. <code>complete.cases()</code> : Identificar Linhas Completas            | 2 |
| 1.3. Estratégias para Lidar com Valores em Falta                               | 3 |
| 1.3.1. Remover Linhas com NAs ( <code>na.omit()</code> )                       | 3 |
| 1.3.2. Remover Linhas com NAs ( <code>drop_na()</code> do <code>tidyr</code> ) | 3 |
| 1.3.3. Imputação Simples (Substituir NAs)                                      | 3 |

#1. Tratamento de Valores em Falta (NA) Valores em falta (representados como NA - Not Available - em R) são muito comuns em datasets reais. É crucial identificá-los e decidir como lidar com eles, pois podem afetar as nossas análises.

## 1.1. Criar um Dataset de Exemplo com NAs

Vamos criar um data frame simples com alguns valores em falta para demonstração.

```
dados_na <- data.frame(  
  ID = 1:5,  
  Nome = c("João", "Maria", "Pedro", "Ana", "Luís"),  
  Idade = c(20, 22, NA, 21, 23),  
  Pontuacao = c(85, NA, 90, 78, NA),  
  Cidade = c("Lisboa", "Porto", "Coimbra", NA, "Faro")  
)  
print(dados_na)
```

| ##   | ID | Nome  | Idade | Pontuacao | Cidade  |
|------|----|-------|-------|-----------|---------|
| ## 1 | 1  | João  | 20    | 85        | Lisboa  |
| ## 2 | 2  | Maria | 22    | NA        | Porto   |
| ## 3 | 3  | Pedro | NA    | 90        | Coimbra |
| ## 4 | 4  | Ana   | 21    | 78        | <NA>    |
| ## 5 | 5  | Luís  | 23    | NA        | Faro    |

## 1.2. Identificar Valores em Falta

### 1.2.1. `is.na()`: Verificar se é NA

A função `is.na()` retorna TRUE se um valor for NA e FALSE caso contrário.

```
is.na(dados_na$Idade) # Verifica a coluna Idade
```

```
## [1] FALSE FALSE TRUE FALSE FALSE
is.na(dados_na)      # Verifica todo o data frame
```

```
##      ID Nome Idade Pontuacao Cidade
## [1,] FALSE FALSE FALSE      FALSE FALSE
## [2,] FALSE FALSE FALSE      TRUE  FALSE
## [3,] FALSE FALSE TRUE      FALSE FALSE
## [4,] FALSE FALSE FALSE      FALSE  TRUE
## [5,] FALSE FALSE FALSE      TRUE  FALSE
```

### 1.2.2. sum(is.na()): Contar NAs por Coluna

Podemos usar `sum(is.na(coluna))` para contar o número de NAs numa coluna, pois TRUE é tratado como 1 e FALSE como 0.

```
# NAs na coluna Idade
sum(is.na(dados_na$Idade))
```

```
## [1] 1
```

```
# NAs na coluna Pontuacao
sum(is.na(dados_na$Pontuacao))
```

```
## [1] 2
```

```
# NAs em todas as colunas (aplicando a cada coluna)
sapply(dados_na, function(x) sum(is.na(x)))
```

```
##      ID      Nome      Idade Pontuacao      Cidade
##      0        0          1          2          1
```

```
# Ou com dplyr e summarise (mais elegante para data frames)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'
##
## The following objects are masked from 'package:stats':
##
##      filter, lag
##
## The following objects are masked from 'package:base':
##
##      intersect, setdiff, setequal, union
```

```
dados_na %>%
  summarise_all(function(x) sum(is.na(x)))
```

```
##      ID Nome Idade Pontuacao Cidade
## 1  0    0     1          2      1
```

### 1.2.3. complete.cases(): Identificar Linhas Completas

Esta função retorna um vetor lógico indicando quais linhas não têm NAs.

```
complete.cases(dados_na)
```

```
## [1] TRUE FALSE FALSE FALSE FALSE
```

```
# Contar o número de linhas completas
sum(complete.cases(dados_na))
```

```
## [1] 1
```

## 1.3. Estratégias para Lidar com Valores em Falta

### 1.3.1. Remover Linhas com NAs (na.omit())

A forma mais simples é remover todas as linhas que contêm pelo menos um NA. Cuidado: Isto pode resultar na perda de muita informação se houver muitos NAs espalhados.

```
dados_sem_na_omit <- na.omit(dados_na)
print(dados_sem_na_omit)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João   20         85 Lisboa
```

### 1.3.2. Remover Linhas com NAs (drop\_na() do tidyr)

O pacote tidyr (também parte do tidyverse) tem uma função mais flexível, drop\_na().

```
# install.packages("tidyr") # Descomentem e executem se não tiverem
library(tidyr)
```

```
# Remover linhas com NA em qualquer coluna
dados_sem_na_tidyr <- dados_na %>%
  drop_na()
print(dados_sem_na_tidyr)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João   20         85 Lisboa
```

```
# Remover linhas apenas se tiverem NA em 'Idade' ou 'Pontuacao'
dados_sem_na_colunas_especificas <- dados_na %>%
  drop_na(Idade, Pontuacao)
print(dados_sem_na_colunas_especificas)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João   20         85 Lisboa
## 2  4 Ana   21         78  <NA>
```

### 1.3.3. Imputação Simples (Substituir NAs)

Em vez de remover, podemos substituir os NAs por um valor. As estratégias mais comuns são: \* Média: Para variáveis numéricas. \* Mediana: Para variáveis numéricas (menos sensível a outliers). \* Moda: Para variáveis categóricas. \* Um valor fixo: Ex: 0, “Desconhecido”.

**Exemplo:** Imputar NAs com a Média da Coluna

```
# Criar uma cópia para não alterar o original
dados_imputados <- dados_na

# Calcular a média da coluna Idade (ignorando NAs)
media_idade <- mean(dados_imputados$Idade, na.rm = TRUE)
print(paste("Média da Idade:", media_idade))
```

```
## [1] "Média da Idade: 21.5"
```

```
# Substituir NAs na coluna Idade pela média
dados_imputados$Idade[is.na(dados_imputados$Idade)] <- media_idade
print(dados_imputados)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João  20.0        85  Lisboa
## 2  2 Maria 22.0         NA   Porto
## 3  3 Pedro 21.5         90 Coimbra
## 4  4  Ana  21.0         78    <NA>
## 5  5 Luís  23.0         NA    Faro
```

```
# Fazer o mesmo para Pontuacao
media_pontuacao <- mean(dados_imputados$Pontuacao, na.rm = TRUE)
dados_imputados$Pontuacao[is.na(dados_imputados$Pontuacao)] <- media_pontuacao
print(dados_imputados)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João  20.0  85.00000  Lisboa
## 2  2 Maria 22.0  84.33333   Porto
## 3  3 Pedro 21.5  90.00000 Coimbra
## 4  4  Ana  21.0  78.00000    <NA>
## 5  5 Luís  23.0  84.33333    Faro
```

**Exemplo:** Imputar NAs com a Moda da Coluna (para categóricas) Para a moda, não há uma função direta no R, mas podemos criá-la ou usar a lógica.

```
# Função para encontrar a moda
get_mode <- function(v) {
  uniqv <- unique(v)
  uniqv[which.max(tabulate(match(v, uniqv)))]
}
```

```
# Imputar NAs na coluna Cidade com a moda
moda_cidade <- get_mode(dados_na$Cidade[!is.na(dados_na$Cidade)])
print(paste("Moda da Cidade:", moda_cidade))
```

```
## [1] "Moda da Cidade: Lisboa"
```

```
dados_imputados_cidade <- dados_na
dados_imputados_cidade$Cidade[is.na(dados_imputados_cidade$Cidade)] <- moda_cidade
print(dados_imputados_cidade)
```

```
##   ID Nome Idade Pontuacao Cidade
## 1  1 João   20        85  Lisboa
## 2  2 Maria  22         NA   Porto
## 3  3 Pedro  NA         90 Coimbra
## 4  4  Ana   21         78  Lisboa
## 5  5 Luís   23         NA    Faro
```

Com dplyr e tidyr para imputação:

```
# Imputar NAs com a média usando dplyr e tidyr::replace_na
dados_imputados_dplyr <- dados_na %>%
  mutate(
    Idade = replace_na(Idade, mean(Idade, na.rm = TRUE)),
    Pontuacao = replace_na(Pontuacao, mean(Pontuacao, na.rm = TRUE))
  )
print(dados_imputados_dplyr)
```

```
##   ID  Nome Idade Pontuacao  Cidade
## 1  1  João  20.0  85.00000  Lisboa
## 2  2  Maria  22.0  84.33333   Porto
## 3  3  Pedro  21.5  90.00000 Coimbra
## 4  4   Ana  21.0  78.00000    <NA>
## 5  5  Luís  23.0  84.33333    Faro
```

**Qual estratégia usar?** Depende do contexto e da quantidade de NAs. \* **Remoção:** Simples, mas pode perder dados valiosos. \* **Imputação:** Mantém mais dados, mas a “imputação” é uma estimativa e pode introduzir viés.

**Parabéns!** Já sabem como identificar e começar a tratar valores em falta!