

Sessão 3.5: Criação de Novas Variáveis

Os vossos formadores

6 de Julho de 2025

Contents

1. Criação de Novas Variáveis (Colunas)	1
1.1. Usando mutate() do dplyr	1
1.1.1. Cálculos Aritméticos Simples	2
1.1.2. Funções Condicionais (ifelse())	2
1.1.3. Funções de Texto	3
1.1.4. Funções de Data e Hora	4
1.1.5. Múltiplas Novas Variáveis	4

1. Criação de Novas Variáveis (Colunas)

A criação de novas variáveis, ou “feature engineering”, é uma parte fundamental da ciência de dados. Permite-nos derivar novas informações a partir dos dados existentes, que podem ser mais úteis para a análise ou modelagem. Vamos usar o dataset mtcars para demonstrar.

```
data(mtcars)
head(mtcars)
```

```
##           mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46  0  1    4    4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02  0  1    4    4
## Datsun 710     22.8   4  108  93 3.85 2.320 18.61  1  1    4    1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44  1  0    3    1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02  0  0    3    2
## Valiant        18.1   6  225 105 2.76 3.460 20.22  1  0    3    1
```

1.1. Usando mutate() do dplyr

Como vimos brevemente, a função `mutate()` do pacote `dplyr` é a ferramenta principal para criar ou modificar colunas.

```
library(dplyr)
```

```
##
## Attaching package: 'dplyr'
##
## The following objects are masked from 'package:stats':
##
##   filter, lag
##
## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

1.1.1. Cálculos Aritméticos Simples

Podemos criar novas colunas com base em operações matemáticas entre colunas existentes.

```
# Criar uma coluna 'cavalos_por_cilindro'
mtcars_novas_vars <- mtcars %>%
  mutate(cavalos_por_cilindro = hp / cyl)
head(mtcars_novas_vars)
```

```
##           mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46 0  1   4    4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02 0  1   4    4
## Datsun 710      22.8   4  108  93 3.85 2.320 18.61 1  1   4    1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44 1  0   3    1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02 0  0   3    2
## Valiant        18.1   6  225 105 2.76 3.460 20.22 1  0   3    1
##           cavalos_por_cilindro
## Mazda RX4                18.33333
## Mazda RX4 Wag            18.33333
## Datsun 710                23.25000
## Hornet 4 Drive            18.33333
## Hornet Sportabout         21.87500
## Valiant                   17.50000
```

```
# Criar uma coluna 'peso_em_kg' (1 lb = 0.453592 kg, mas 'wt' está em 1000 lbs)
mtcars_novas_vars <- mtcars_novas_vars %>%
  mutate(peso_em_kg = wt * 1000 * 0.453592)
head(mtcars_novas_vars)
```

```
##           mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46 0  1   4    4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02 0  1   4    4
## Datsun 710      22.8   4  108  93 3.85 2.320 18.61 1  1   4    1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44 1  0   3    1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02 0  0   3    2
## Valiant        18.1   6  225 105 2.76 3.460 20.22 1  0   3    1
##           cavalos_por_cilindro peso_em_kg
## Mazda RX4                18.33333  1188.411
## Mazda RX4 Wag            18.33333  1304.077
## Datsun 710                23.25000  1052.333
## Hornet 4 Drive            18.33333  1458.298
## Hornet Sportabout         21.87500  1560.356
## Valiant                   17.50000  1569.428
```

1.1.2. Funções Condicionais (ifelse())

A função `ifelse(condicao, valor_se_verdadeiro, valor_se_falso)` é excelente para criar variáveis categóricas baseadas em condições.

```
# Criar uma coluna 'eficiencia_combustivel' (alta/baixa) baseada no 'mpg'
mtcars_novas_vars <- mtcars_novas_vars %>%
  mutate(eficiencia_combustivel = ifelse(mpg > 20, "Alta", "Baixa"))
head(mtcars_novas_vars)
```

```
##           mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46 0  1   4    4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02 0  1   4    4
```

```
## Datsun 710      22.8   4  108  93 3.85 2.320 18.61 1 1   4   1
## Hornet 4 Drive 21.4   6  258 110 3.08 3.215 19.44 1 0   3   1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02 0 0   3   2
## Valiant        18.1   6  225 105 2.76 3.460 20.22 1 0   3   1
##               cavalos_por_cilindro peso_em_kg eficiencia_combustivel
## Mazda RX4      18.33333   1188.411                      Alta
## Mazda RX4 Wag  18.33333   1304.077                      Alta
## Datsun 710     23.25000   1052.333                      Alta
## Hornet 4 Drive 18.33333   1458.298                      Alta
## Hornet Sportabout 21.87500   1560.356                  Baixa
## Valiant        17.50000   1569.428                  Baixa
```

```
# Criar uma coluna 'potencia_categoria' (fraca/media/forte)
```

```
mtcars_novas_vars <- mtcars_novas_vars %>%
  mutate(potencia_categoria = case_when(
    hp < 100 ~ "Fraca",
    hp >= 100 & hp < 150 ~ "Média",
    hp >= 150 ~ "Forte"
  ))
head(mtcars_novas_vars)
```

```
##               mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46 0 1   4   4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02 0 1   4   4
## Datsun 710     22.8   4  108  93 3.85 2.320 18.61 1 1   4   1
## Hornet 4 Drive 21.4   6  258 110 3.08 3.215 19.44 1 0   3   1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02 0 0   3   2
## Valiant        18.1   6  225 105 2.76 3.460 20.22 1 0   3   1
##               cavalos_por_cilindro peso_em_kg eficiencia_combustivel
## Mazda RX4      18.33333   1188.411                      Alta
## Mazda RX4 Wag  18.33333   1304.077                      Alta
## Datsun 710     23.25000   1052.333                      Alta
## Hornet 4 Drive 18.33333   1458.298                      Alta
## Hornet Sportabout 21.87500   1560.356                  Baixa
## Valiant        17.50000   1569.428                  Baixa
##               potencia_categoria
## Mazda RX4      Média
## Mazda RX4 Wag  Média
## Datsun 710     Fraca
## Hornet 4 Drive Média
## Hornet Sportabout Forte
## Valiant        Média
```

1.1.3. Funções de Texto

Podemos manipular colunas de texto para criar novas. **Exemplo:** Se tivéssemos uma coluna de nomes completos e quiséssemos apenas o primeiro nome.

```
# Criar um data frame de exemplo com nomes
```

```
dados_nomes <- data.frame(
  Nome_Completo = c("Maria Silva", "João Santos", "Ana Pereira")
)
```

```
# Extrair o primeiro nome
```

```
dados_nomes <- dados_nomes %>%
  mutate(Primeiro_Nome = sub(" .*", "", Nome_Completo)) # Remove tudo depois do primeiro espaço
```

```
print(dados_nomes)
```

```
## Nome_Completo Primeiro_Nome
## 1 Maria Silva Maria
## 2 João Santos João
## 3 Ana Pereira Ana
```

1.1.4. Funções de Data e Hora

Se tivéssemos colunas de data, poderíamos extrair o ano, mês, dia, etc., ou calcular diferenças de tempo.

```
# install.packages("lubridate") # Descomentem e executem se não tiverem
library(lubridate)
```

```
##
## Attaching package: 'lubridate'
## The following objects are masked from 'package:base':
##
## date, intersect, setdiff, union
```

```
dados_datas <- data.frame(
  Data_Nascimento = c("1990-05-15", "1995-11-20", "2000-01-01")
)

dados_datas <- dados_datas %>%
  mutate(Data_Nascimento = ymd(Data_Nascimento)) %>% # Converter para formato de data
  mutate(Ano_Nascimento = year(Data_Nascimento),
         Mes_Nascimento = month(Data_Nascimento),
         Dia_Nascimento = day(Data_Nascimento))
print(dados_datas)
```

```
## Data_Nascimento Ano_Nascimento Mes_Nascimento Dia_Nascimento
## 1 1990-05-15 1990 5 15
## 2 1995-11-20 1995 11 20
## 3 2000-01-01 2000 1 1
```

```
# Calcular idade (aproximada)
dados_datas <- dados_datas %>%
  mutate(Idade_Atual = year(Sys.Date()) - Ano_Nascimento)
print(dados_datas)
```

```
## Data_Nascimento Ano_Nascimento Mes_Nascimento Dia_Nascimento Idade_Atual
## 1 1990-05-15 1990 5 15 35
## 2 1995-11-20 1995 11 20 30
## 3 2000-01-01 2000 1 1 25
```

1.1.5. Múltiplas Novas Variáveis

Podemos criar várias novas variáveis numa única chamada mutate().

```
mtcars_multi_vars <- mtcars %>%
  mutate(
    litros_por_100km = 235.21 / mpg, # Converter mpg para L/100km
    cilindros_categoria = as.factor(cyl), # Converter para fator
    is_automatico = ifelse(am == 0, "Sim", "Não") # 0=automatic, 1>manual
```

```
)
head(mtcars_multi_vars)
```

```
##           mpg cyl disp  hp drat   wt  qsec vs am gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46 0  1   4   4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02 0  1   4   4
## Datsun 710     22.8   4  108  93 3.85 2.320 18.61 1  1   4   1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44 1  0   3   1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02 0  0   3   2
## Valiant        18.1   6  225 105 2.76 3.460 20.22 1  0   3   1
##           litros_por_100km cilindros_categoria is_automatico
## Mazda RX4              11.20048                6           Não
## Mazda RX4 Wag          11.20048                6           Não
## Datsun 710              10.31623                4           Não
## Hornet 4 Drive          10.99112                6           Sim
## Hornet Sportabout       12.57807                8           Sim
## Valiant                 12.99503                6           Sim
```

```
str(mtcars_multi_vars)
```

```
## 'data.frame':   32 obs. of  14 variables:
## $ mpg          : num  21 21 22.8 21.4 18.7 18.1 14.3 24.4 22.8 19.2 ...
## $ cyl          : num  6 6 4 6 8 6 8 4 4 6 ...
## $ disp         : num  160 160 108 258 360 ...
## $ hp          : num  110 110 93 110 175 105 245 62 95 123 ...
## $ drat         : num  3.9 3.9 3.85 3.08 3.15 2.76 3.21 3.69 3.92 3.92 ...
## $ wt          : num  2.62 2.88 2.32 3.21 3.44 ...
## $ qsec        : num  16.5 17 18.6 19.4 17 ...
## $ vs          : num  0 0 1 1 0 1 0 1 1 1 ...
## $ am          : num  1 1 1 0 0 0 0 0 0 0 ...
## $ gear        : num  4 4 4 3 3 3 3 4 4 4 ...
## $ carb        : num  4 4 1 1 2 1 4 2 2 4 ...
## $ litros_por_100km : num  11.2 11.2 10.3 11 12.6 ...
## $ cilindros_categoria: Factor w/ 3 levels "4","6","8": 2 2 1 2 3 2 3 1 1 2 ...
## $ is_automatico   : chr  "Não" "Não" "Não" "Sim" ...
```

Parabéns! Já sabem como criar novas variáveis nos vossos data frames! Esta é uma habilidade muito poderosa na ciência de dados.