

# Sessão 3: Exercícios Práticos

Os vossos formadores

6 de Julho de 2025

## Contents

|                                                          |          |
|----------------------------------------------------------|----------|
| <b>Exercícios Práticos: dplyr, NAs e Novas Variáveis</b> | <b>1</b> |
| <b>Exercício 1:</b> Exploração e Identificação de NAs    | 2        |
| <b>Exercício 2:</b> Tratamento de Valores em Falta       | 2        |
| <b>Exercício 3:</b> Criação de Novas Variáveis           | 2        |
| <b>Exercício 4:</b> Agrupamento e Resumo com dplyr       | 3        |

## Exercícios Práticos: dplyr, NAs e Novas Variáveis

Olá! Nesta sessão de exercícios, vamos consolidar os vossos conhecimentos sobre manipulação de dados com dplyr, tratamento de valores em falta e criação de novas variáveis. Vamos trabalhar com um dataset simulado de “Dados de Clientes”.

*a\*Preparação:* Criar o Dataset de Exemplo Primeiro, vamos criar um ficheiro CSV de exemplo com alguns valores em falta para os exercícios. Certifiquem-se de que o vosso diretório de trabalho está correto ou que o RStudio Project está ativo.

```
# Criar um data frame de exemplo com NAs
dados_clientes <- data.frame(
  ID_Cliente = 1001:1010,
  Nome = c("Alice", "Bernardo", "Carla", "Diogo", "Eva", "Filipe", "Gabriela", "Hugo", "Inês", "Joana"),
  Idade = c(25, 30, NA, 22, 35, 28, NA, 40, 27, 33),
  Rendimento_Mensal = c(1500, 2200, 1800, 1400, NA, 2500, 1900, 3000, NA, 2100),
  Genero = c("F", "M", "F", "M", "F", "M", "F", "M", "F", "M"),
  Cidade = c("Lisboa", "Porto", "Coimbra", "Braga", "Lisboa", "Porto", "Coimbra", "Braga", "Lisboa", "Porto"),
  Compras_Ultimos_6_Meses = c(5, 8, 3, 10, 6, 7, 4, 12, 9, 5)
)

# Introduzir alguns NAs adicionais para testar
dados_clientes$Rendimento_Mensal[c(5, 9)] <- NA
dados_clientes$Idade[3] <- NA

# Guardar o data frame num ficheiro CSV
write.csv(dados_clientes, "dados_clientes.csv", row.names = FALSE)

print("Ficheiro 'dados_clientes.csv' criado na vossa pasta de trabalho.")

## [1] "Ficheiro 'dados_clientes.csv' criado na vossa pasta de trabalho."

# Carregar o pacote dplyr
library(dplyr)

##
```

```
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union

# Carregar o pacote tidyr (para drop_na e replace_na)
library(tidyr)

# Importar o dataset
meus_clientes <- read.csv("dados_clientes.csv")
head(meus_clientes)
```

```
##   ID_Cliente   Nome Idade Rendimento_Mensal Genero  Cidade
## 1      1001    Alice   25           1500      F   Lisboa
## 2      1002 Bernardo   30           2200      M    Porto
## 3      1003    Carla   NA           1800      F Coimbra
## 4      1004    Diogo   22           1400      M    Braga
## 5      1005      Eva   35              NA      F   Lisboa
## 6      1006   Filipe   28           2500      M    Porto
## Compras_Ultimos_6_Meses
## 1              5
## 2              8
## 3              3
## 4             10
## 5              6
## 6              7
```

## Exercício 1: Exploração e Identificação de NAs

1. **Explorar:** Obtenham um summary() e str() do meus\_clientes.
2. **Contar NAs:** Quantos valores em falta existem em cada coluna (Idade e Rendimento\_Mensal)?
3. **Linhas Completas:** Quantas linhas no data frame não têm NAs?

```
# Escrevam o vosso código aqui para o Exercício 1
```

## Exercício 2: Tratamento de Valores em Falta

1. **Remover NAs:** Criem um novo data frame chamado clientes\_sem\_na que remova todas as linhas com valores em falta. Quantas linhas restaram?
2. **Imputar Idade:** Criem um novo data frame chamado clientes\_imputado\_idade onde os NAs na coluna Idade são substituídos pela média da Idade (ignorando os NAs para o cálculo da média).
3. **Imputar Rendimento:** No clientes\_imputado\_idade, substituam os NAs na coluna Rendimento\_Mensal pela mediana do Rendimento\_Mensal (ignorando os NAs para o cálculo da mediana). Chame o resultado final de clientes\_limpo.

```
# Escrevam o vosso código aqui para o Exercício 2
```

## Exercício 3: Criação de Novas Variáveis

Continuem a trabalhar com o clientes\_limpo (o data frame sem NAs e com imputação).

1. **Rendimento Anual:** Criem uma nova coluna chamada `Rendimento_Anual` que seja o `Rendimento_Mensal` multiplicado por 12.
2. **Categoria de Idade:** Criem uma nova coluna chamada `Categoria_Idade` com base na `Idade`:
  - “Jovem” se `Idade < 25`
  - “Adulto” se `Idade >= 25` e `Idade < 35`
  - “Senior” se `Idade >= 35`
3. **Frequência de Compra:** Criem uma nova coluna chamada `Frequencia_Compra` com base em `Compras_Ultimos_6_Meses`:
  - “Baixa” se `Compras_Ultimos_6_Meses <= 5`
  - “Média” se `Compras_Ultimos_6_Meses > 5` e `Compras_Ultimos_6_Meses <= 8`
  - “Alta” se `Compras_Ultimos_6_Meses > 8`

*# Escrevam o vosso código aqui para o Exercício 3*

### Exercício 4: Agrupamento e Resumo com dplyr

Continuem a trabalhar com o `clientes_limpo` (com as novas variáveis criadas).

1. Média de Idade por Género: Calculem a média da `Idade` para cada `Genero`.
2. Rendimento Médio por Cidade: Calculem o `Rendimento_Mensal` médio e o número de clientes (`n()`) para cada `Cidade`.
3. Resumo por Categoria de Idade e Género: Calculem o `Rendimento_Anual` médio e o número de clientes (`n()`) para cada combinação de `Categoria_Idade` e `Genero`. Ordenem os resultados pelo `Rendimento_Anual` médio em ordem decrescente.

*# Escrevam o vosso código aqui para o Exercício 4*

**Parabéns!** Completaram os exercícios da Sessão 3!